

Case Study Datengestützte Entscheidungsfindung

Studiengang	M.Sc. Wirtschaftsinformatik
Modul	Business Intelligence & Analytics
Fachsemester	2 (FS24)
Vorgelegt von	Annamária Sréter, Pjeter Bushi
Eingereicht am	23.06.2024

Management Summary

Im Rahmen des Moduls Business Intelligence & Analytics wurde diese Case Study erstellt, um die datengestützte Entscheidungsfindung anhand eines fiktiven Unternehmens zu demonstrieren. Das Unternehmen, «BeHappy! AG», möchte durch eine Analyse des World Happiness Reports (WHR) und ergänzender Daten herausfinden, welche Faktoren die Zufriedenheit der Bevölkerung beeinflussen, um neue Produkte zu entwickeln.

Hauptziele der Case Study:

1. Identifikation der wichtigsten Indikatoren im WHR, die die Zufriedenheit der Bevölkerung signifikant beeinflussen.
2. Untersuchung regionaler Unterschiede dieser Indikatoren.

Methodik

Die Case Study folgt dem «*five-step approach to data-driven decision-making*» von Bernard Marr:

1. Zieldefinition und Forschungsfragen: Festlegung der zu treffenden Entscheidungen und der benötigten Datensätze.
2. Datenbeschaffung: Sammlung relevanter Daten aus dem WHR und ergänzenden Quellen
3. Datenanalyse: Durchführung einer Korrelationsanalyse zur Identifikation signifikanter Zusammenhänge.
4. Präsentation der Ergebnisse: Visuelle Aufbereitung der Analyseergebnisse zur Unterstützung der Entscheidungsfindung.

Ergebnisse

- Globale Indikatoren: Die wichtigsten Faktoren für die Zufriedenheit sind sozialer Rückhalt (Familie), Lebenserwartung und das BIP pro Kopf. Weniger relevante Faktoren sind der materielle Fussabdruck, die Waldfläche und die Mordrate.
- - Regionale Unterschiede: In Afrika spielen familiäre Unterstützung und BIP pro Kopf eine zentrale Rolle. In Amerika sind Gesundheit und Familie dominierend, während in Europa Freiheit und Vertrauen in die Regierung wichtiger sind.

Schlussfolgerungen

Die Analyse zeigt, dass unterschiedliche Regionen verschiedene Prioritäten in Bezug auf Zufriedenheitsfaktoren haben. Die BHAG kann diese Erkenntnisse nutzen, um gezielte Produkte und Dienstleistungen zu entwickeln, die den spezifischen Bedürfnissen der jeweiligen Regionen entsprechen. Weitere detaillierte Analysen werden empfohlen, um spezifische Marktsegmente tiefer zu untersuchen und spezifischere Entscheidungen treffen zu können.

Inhaltsverzeichnis

Management Summary 0
Hauptziele der Case Study: 0
Methodik 0
Ergebnisse 0
Schlussfolgerungen 0
Kapitel 1 – Einleitung 0
Abgrenzung 0
Ausgangslage 1
Der «*World Happiness Report*» (WHR) 1
Forschungsfragen 2
Zielsetzung 2
Publikum 2
Struktur 3
Kapitel 2 – Datenbeschaffung 4
Recherche 4
World Happiness Report (WHR) 4
Ergänzende Datenquellen «additional data» 5
Weitere Datenquellen «supplemental data» 6
Zusammenfassung 6
Kapitel 3 – Datenanalyse 7
Sichtung der Daten 7
Prüfung des Rohdatenformats 8
Definition Datenbankschema 9
Tabelle «*country*» 9
Tabelle «*metric_definition*» 9
Tabelle «*metric*» 9
Konvertierung 10
Meta-Datenanalyse 12
Datenanalyse 13
Korrelationsanalyse 13
Positive Korrelation 16
Negative Korrelation 16
Neutrale Korrelation 17
Zusammenfassung 17
Kapitel 4 – Präsentation der Resultate 18

Visualisierung 18
Vergleiche 19
Korrelationen (Zusammenhänge) 19
Teil eines Ganzen (Hierarchien) 20
Zeitreihendaten 20
Verteilung 21
Geografie & Andere 21
Resultate 22
Forschungsfrage 1 – «Welche Indikatoren des WHR haben einen signifikanten Einfluss auf die Zufriedenheit einer Bevölkerung» 22
Forschungsfrage 2 – «Unterscheiden sich die relevanten Indikatoren verschiedener Regionen» 24
Zusammenfassung 26
Rückblick 27
Ausblick 27
Literaturverzeichnis 28
Abbildungsverzeichnis 29
Eigenständigkeitserklärung 30

Kapitel 1 – Einleitung

Diese Case Study zum Thema «*Von Daten zu Entscheidungen*» wird im Rahmen des Masterstudiengangs Wirtschaftsinformatik im Modul «*Business Intelligence & Analytics*» vorgelegt. Ziel dieser Case Study ist es, beispielhaft darzulegen, wie anhand der von Bernard Marr in «*five-step approach to data-driven decision-making*» (Marr, undatiert) beschriebenen Vorgehensweise auf Basis von Daten Entscheidungen in Unternehmen getroffen werden können. Hierfür wird sich diese Case Study mit einem beispielhaften Business Case eines fiktiven Unternehmens beschäftigen und versuchen, die von der Geschäftsführung gestellten Fragen anhand von Daten beantworten zu können und sie bei der Entscheidungsfindung zu unterstützen.



Abbildung 1 – Skizze: Die fünf Schritte des data-driven decision-making

Die Von Bernard Marr beschriebene «*five-step approach to data-driven decision-making*» Vorgehensweise beschreibt den Prozess von Fragestellung zur datengestützten Entscheidungsfindung in fünf Schritten. Er sieht vor, dass zunächst klar definiert werden soll, welche Entscheidungen getroffen werden bzw. welche Fragen beantwortet werden sollen. Anschliessend kann auf dieser Basis bestimmt werden, welche Datensätze benötigt bzw. beschafft werden müssen. Im dritten Schritt werden die nun vorhandenen Informationen im Kontext der eingangs definierten Fragestellungen analysiert. Anschliessend, im vierten Schritt, sollen die Resultate der Analyse visuell aufbereitet und den Entscheidungsträgern präsentiert werden. Der fünfte und letzte Schritt wird nun von der Geschäftsführung durchgeführt. Er sieht vor, dass auf Basis der Resultate, der Analyse, nun eine entsprechende Entscheidung getroffen wird. Eine datengestützte Entscheidung.

Abgrenzung

Da diese Arbeit im Rahmen des Moduls «*Business Intelligence & Analytics*» durchgeführt wird, werden ausschliesslich die Schritte eins bis vier des «*five-step approach to data-driven decision-making*» behandelt.

fünfte Schritt «*Entscheidungsfindung auf Basis der gewonnen Insights*» wird nicht mehr Teil des Umfangs dieser Arbeit sein. Dennoch wird dieser Teil im Kapitel Ausblick angeschnitten.

Ausgangslage

Die vorliegende Arbeit wird sich mit der Beantwortung der im nächsten Abschnitt dargestellten Forschungsfragen eines fiktiven Unternehmens beschäftigen. Der Name des Unternehmens lautet «***BeHappy! AG***» (nachfolgend **BHAG** genannt). Die BHAG konzentriert sich auf die Herstellung und den Vertrieb von Wohlfühlprodukten. Dem Unternehmen liegt das Wohlbefinden und die Zufriedenheit seiner Kunden am Herzen. Denn mit dem Erzeugen von Wohlbefinden und zufriedenen Kunden generiert das Unternehmen seinen Umsatz.

Die BHAG hat sich dazu entschlossen, eine interne, weitläufige Marktanalyse zu starten und sich ggf. – abhängig von den Ergebnissen der Analyse – auch in für die BHAG unbekanntes Terrain vorzuwagen.

Ein eigenes, internes Analysten-Team wird vom Unternehmen bereits unterhalten, von welchem einige Kapazität für die neue Analyse abgezogen wird.

Da die BHAG noch keine Konkrete Vorstellung davon hat, welche Technologien sie einsetzen oder produzieren (oder welche Services sie bereitstellen) möchte, will sie unvoreingenommen mit Hilfe der datengestützen Entscheidungsfindung anhand des «*five-step approach to data-driven decision-making*» zunächst eine grobe Richtung einschlagen und stellt sich daher zunächst die Frage, welche groben Themenbereiche den grössten Einfluss auf die Zufriedenheit der Menschen haben. Mit den Ergebnissen der Analyse erhofft sich die BHAG das Themenfeld weiter eingrenzen zu können, in diesem wiederum weitere Informationen beschaffen zu können und dieses detaillierter analysieren zu können, um schliesslich ein passendes Produkt oder Service auf den Markt bringen zu können.

Daher beschliesst die Unternehmensleitung, zunächst eine Makroperspektive einzunehmen und untersuchen zu lassen, welche Einflüsse auf das Zufriedenheitsempfinden der Menschen grob bestehen, um diese anschliessend im Detail untersuchen zu können.

Der «*World Happiness Report*» (WHR)

Die BHAG hat sich daher dazu entschlossen, ihre Analysten darauf anzusetzen, den «***World Happiness Report***» (WHR, et. al, 2024) (nachfolgend als **WHR** bezeichnet) als ersten Einstiegspunkt zu untersuchen, dessen Daten zu analysieren und dem Unternehmen die erste grobe Richtung aufzeigen zu können.

Der WHR – im Speziellen der Indikator «*Happiness Score*» – soll einen Eindruck über die Zufriedenheit verschiedener Nationen vermitteln. Der WHR enthält neben dem «*Happiness Score*» noch weitere Indikatoren, welche auf den folgenden Seiten näher ausgeführt werden.

Der WHR enthält ca. zehn Indikatoren, deren Relevanz im Rahmen dieser Case Study von dem Analysten-Team geprüft werden sollen, um festzustellen, welche Indikatoren tatsächlich einen signifikanten Einfluss auf die Zufriedenheit der jeweiligen Bevölkerungen haben, und ob diese ggf. von Nation zu Nation, von Kontinent zu Kontinent unterschiedlich sind.

Forschungsfragen

Nachfolgend werden die Forschungsfragen aufgelistet, welche sich aus den Anforderungen und Vorhaben des Unternehmens ergeben und welche es zu bearbeiten gilt.

1. Welche **Indikatoren** des WHR haben einen **signifikanten Einfluss** auf die Zufriedenheit einer Bevölkerung?
    a. Welche 3 Features haben den grössten Einfluss?
    b. Welche 3 Features haben den niedrigsten Einfluss?
2. **Unterscheiden** sich die relevanten **Indikatoren verschiedener Regionen**?
    a. Wie unterschieden sie sich von Kontinent zu Kontinent?

Zielsetzung

Die BHAG möchte neue Märkte erschliessen und ist bzgl. des schlussendlich zu produzierenden Produktes oder des bereitzustellenden Service sehr anpassungsfähig und bereit in neue Märkte vorzudringen. Daher werden die Analysten der BHAG die Aufgabe haben, Einflüsse auf die Zufriedenheit und das Wohlbefinden der entspr. Bevölkerungen verschiedener Länder zu untersuchen.

Dies wird zunächst auf einem Makrolevel passieren. Es werden zunächst grobe Bereiche analysiert. Vielversprechende Bereiche können in einem zweiten Inkrement schliesslich detaillierter analysiert werden und ggf. wieder weiter unterteilt und in einem dritten und vierten Inkrement weiter untersucht werden.

Am Ende dieser Analyse sollen also drei grosse Themenbereiche stehen, welche für die Zufriedenheit und das Wohlbefinden von Menschen eine entspr. grosse Rolle spielen. Ggf. aber kann auch ein Resultat sein, dass die beschafften Informationen unvollständig sind und weitere Daten beschafft werden müssen. Dieses Risiko ist nie vollständig auszuschliessen

Publikum

Diese Arbeit dient der Dokumentation der in der BHAG vorgenommenen Schritte zur datengestützten Entscheidungsfindung nach dem «*five-step approach to data-driven decision-making*» zur Erreichung der eingangs erwähnten Ziele, welche die BHAG bzgl. der Erschliessung neuer Märkte, verfolgt.

Diese Arbeit richtet sich daher an alle diejenigen Personen, welche ein Interesse am «*five-step approach to data-driven decision-making*» haben und anhand dieser Arbeit ein tieferes Verständnis für datengestütze Entscheidungsfindungsprozesse erlangen möchten.

Struktur

Diese Case Study richtet sich am «*five-step framework for moving from data to decisions*» aus und unterteilt sich daher in fünf entspr. Kapitel.

Kapitel 1 – die Einleitung – behandelt bereits **Schritt 1**. Die Definition der Ziele, der Formulierung konkreter Forschungsfragen oder Hypothesen, sowie das Festlegen der benötigten Informationen. Mit Abschluss dieses Schrittes ist bekannt, welche Ziele verfolgt werden und welche Informationen benötigt werden, damit anschliessend mit der Datenbeschaffung fortgefahren werden kann.

Kapitel 2 – die Datenbeschaffung – behandelt **Schritt 2**. Herausfinden, ob die Daten bereits im Unternehmen vorhanden sind, oder ob sie beschafft werden müssen. Ggf. müssen die Daten selbst erhoben werden oder das Erheben in Auftrag gegeben werden. Mit dem Abschluss dieses Schrittes sind die benötigten Daten vorhanden und die Analyse kann begonnen werden.

Kapitel 3 – die Datenanalyse – behandelt **Schritt 3**. Durchführung der Datenanalyse unter Zuhilfenahme der geeigneten Methoden (geeignete Methoden müssen nach eigenem Ermessen ausgewählt werden). Am Ende dieses Schrittes stehen konkrete Resultate und Antworten auf die initial gestellten Forschungsfragen und es kann mit der Präsentationsvorbereitung begonnen werden.

Kapitel 4 – die Präsentation – behandelt **Schritt 4**. Die Präsentation der zuvor erarbeiteten Resultate und mögliche Antworten auf die initial gestellten Fragen und Anforderungen.

Kapitel 2 – Datenbeschaffung

Bevor mit einer Analyse begonnen werden kann, müssen die entspr. Daten beschafft werden und in ein entspr. Format gebracht werden. Auf dieses Format wird im Folgenden noch näher eingegangen. Die benötigten Daten können entweder

1. bereits erhoben worden sein oder auf sonstige Art und Weise zur Verfügung stehen. Sei es durch ein bereits durchgeführtes eigenständiges Erheben, den Einkauf oder das Vorhandensein von Informationen (inhärent intern erhoben).
2. Oder die Informationen müssen noch erhoben werden, da sie noch nicht existieren. Dies kann in Form von Umfragen, dem Generieren von Informationen anhand anderer Informationen (Data Mining) oder anderen geeigneten Methoden zum Erheben von Daten sein.

Recherche

Basierend auf den Anforderungen der Geschäftsleitung (den in Kapitel 1 – Einleitung genannten Forschungsfragen) kann im Intranet und Internet gezielt nach den benötigten Informationen gesucht werden. Das Analysten-Team kommt schnell zu Ergebnissen wie bspw. dem «***World Happiness Report***» (WHR, et. al, 2024) **(WHR)**, welcher online kostenlos zur Verfügung steht. Der WHR enthält Informationen über die Zufriedenheit der Menschen verschiedener Länder über mehrere Jahre und eignet sich daher als Indikator. Der WHR allein enthält allerdings nicht besonders viele Indikatoren, weshalb noch weitere Datensätze gesucht werden, welche die Zufriedenheit von Menschen beeinflussen könnten.

World Happiness Report (WHR)

Der WHR besteht aus den folgenden Features, welche nachfolgend näher erläutert werden.

Happiness Rank	Ordnet die Länder auf einer diskreten Skala wobei der niedrigste Rang das Land mit der höchsten Zufriedenheit bezeichnet.
Happiness Score	Der errechnete Durchschnitt der subjektiven Zufriedenheit der Bevölkerung des jeweiligen Landes.
Economy	Die Wirtschaft des Landes. Der Indikator misst das Bruttoinlandsprodukt pro Kopf, welcher im Allgemeinen mit einem höheren Lebensstandard und mehr wirtschaftlicher Sicherheit verbunden wird und daher je höher je besser zu interpretieren ist.
Family	Ggf. auch Social Support genannt. Dieser Indikator bewertet, ob und in welchem Masse sich eine Person in schwierigen

	Zeiten auf die Unterstützung von sozialen Systemen verlassen kann. Dabei kann es sich um natürliche soziale Systeme wie Familie und Freund sowie um künstliche soziale Systeme wie staatliche Sozialleistungen handeln.
Health	Dieser Indikator misst die durchschnittliche Lebenserwartung eines gesunden Menschen des jeweiligen Landes.
Freedom	Die Freiheit, eigene Lebensentscheidungen zu treffen. Dieser Indikator misst, wie frei sich die Menschen in ihrer Entscheidungsfindung fühlen. Dazu gehören bspw. die persönliche wie die berufliche Freiheit, Entscheidungen ohne erhebliche Einschränkungen und Zwänge treffen zu können
Trust	Das Vertrauen in Regierung und Geschäftsleute. Dieser Indikator misst das Mass an Vertrauen, das die Menschen ihrer Regierung und Geschäftsleuten entgegenbringen.
Generosity	Spendenverhalten und ehrenamtliches Engagement. Der Indikator misst, wie grosszügig die Menschen des jeweiligen Landes sich verhalten.
Dystopia Residual	Dieser Indikator dient dem WHR als unterster Referenzpunkt für die Lebensqualität, um die Werte anderer Länder besser vergleichen zu können.

Der WHR bietet somit eine gute Grundlage mit akzeptablen Basisinformationen, was massgebend zur Zufriedenheit der Menschen beiträgt.

Ergänzende Datenquellen «additional data»

Der WHR alleine reicht dem Analysten-Team noch nicht aus. Es werden noch weitere ergänzende Informationen gewünscht, die in die spätere Analyse mit einfliessen sollen, um den WHR zu ergänzen. Daher wurden weitere Datensätze bezogen, welche nachfolgend aufgelistet und erläutert werden. (World Bank, kein Datum)

Cars, Trucks, Busses per 1000	Dieser Datensatz ergänzt den WHR um die Information, wie viele Fahrzeuge auf 1000 Einwohner in dem Jeweiligen Land kommen. Diese Information kann ggf. Aussagen über Mobilität, Wohlstand, etc. ermöglichen.
Carbon Dioxide Consumption	Beschreibt den co2 Ausstoss des jeweiligen Landes
Waldfläche	Diese Datensatz bietet Informationen darüber, wie viel Quadradkilometer de Landes bewalded sind, was ggf. ebenfalls Einfluss auf die Zufriedenheit der Bevölkerung haben kann (Erholungsgebiete)
Inflation	Inflationsdaten des Landes in Prozent
Mordrate	Homizide pro 100.000 Einwohner
Urban Population Growth	Das jährliche Wachstum der urbanen Fläche in Prozent
Personal Integrity and Security	Der offizielle personal «integrity and security index» der jeweiligen Länder
Material Footprint	Der Materialfussabdruck pro Einwohner in kg
Sustainable Development	Der offizielle «sustainable development index»

Political System	Eine Klassifizierung der Länder in vier Kategorien 0 – 3 wobei 0 eine geschlossene Autokratie ist und 3 eine liberale Demokratie.

Weitere Datenquellen «supplemental data»

Die weiteren Datenquellen (auch «supplemental data» genannt) werden nicht direkt für die Analyse benötig. Das bedeutet, diese Datensätze enthalten nicht direkt die Daten, welche Analysiert werden. Allerdings enthalten sie Informationen welche für die Vereinfachung oder Verdeutlichung der späteren Resultate oder Queries benötigt wird.

Es wurde ein Datensatz mit Informationen über alle Länder der Erde (GitHub, 2024) bezogen. Dies sind rudimentäre Informationen wie Name, Länderkürzel (ISO-3, ISO-2), Kontinent, Region, und weitere.

Diese Informationen werden für die Gruppierung der Länder benötigt und deren Anwendung wird in den Abschnitten des Kapitel 3 – Datenanalyse noch verdeutlicht.

Zusammenfassung

Die benötigten Informationen bzw. Datensätze wurden nun bezogen. Diese Daten liegen dem Analysten-Team nun in Form von XLSX- und CSV-Dateien vor. Für den WHR liegen mehrere Dateien (für jedes Jahr eine Datei) und pro ergänzendem Datensatz eine Datei vor. Die ergänzenden Datensätze enthalten die Informationen über mehrere Jahre aufgeteilt über mehrere Spalten.

Damit liegen nun die benötigten Informationen vor und es kann mit Schritt 3 – der Datenanalyse – fortgefahren werden.

Kapitel 3 – Datenanalyse

Im vorherigen Kapitel 2 – Datenbeschaffung wurden die Daten für die Analyse beschafft. Anhand der gesetzten Ziele und den Forschungsfragen konnten die gewünschten Datensätze ausfindig gemacht und bezogen werden. Anhand dieser Informationen können die Analysten nun ihre Analysen durchführen. In diesem Kapitel wird erläutert, wie das Analysten-Team bei der Analyse der beschafften Daten vorgegangen ist und auf welche Herausforderungen sie dabei gestossen sind.

Sichtung der Daten

Die beschafften Datensätze müssen nun zunächst gesichtet werden. In diesem Prozess werden die Datensätze auf ihre Inhalte, Vollständigkeit und ihr Format überprüft.

Die Daten sollten für alle Länder und Jahre genügend Informationen aufweisen, sodass davon Insights abgeleitet werden können. Sind die Datensätze zu spärlich besetzt, so werden die daraus gezogenen Rückschlüsse und gewonnenen Insight zu ungenau und sollten nicht für weitere Entscheidungen genutzt werden.

Die Richtigkeit von Daten, welche von Dritten erhoben wurden, kann meist nur mühevoll verifiziert werden. Es empfiehlt sich, den Data-Provider sowie dessen Methoden gewissenhaft zu prüfen. Ebenfalls empfiehlt es sich Interessens- und sonstige Konflikte von Data-Providern zu überprüfen, da diese ggf. Einfluss auf die Inhalte der Data-Sets haben können. Wenn Daten als Grundlage für Entscheidungen genutzt werden, was heutzutage mehr und mehr der Fall ist, kann Sorglosigkeit hier schwerwiegende Konsequenzen haben.

Das Format der Daten hingegen ist nicht ausschlaggebend, jedoch gilt es zu beachten, dass für verschiedene Formate und Arten von Daten auch verschiedene Konverter oder Analysemethoden verwendet werden müssen. Im Falle der in dieser Case Study untersuchten Daten, sind ausschliesslich nummerische Daten in Form von XLSX und CSV Dateien zu untersuchen. Jedoch sind auch diese Daten verschieden formatiert bzw. angeordnet.

Prüfung des Rohdatenformats

Die gesammelten Daten stehen in verschiedenen Anordnungen zur Verfügung. Generell handelt es sich dabei immer um «*row-column-based*» Informationen, allerding variiert deren Anordnung. Nachfolgendes Beispiel soll dies verdeutlichen.

	A	B	C	D	E	F	G	H	I	J	K
1	Country nam	Regional indi	Overall rank	Ladder score	Standard erro	upperwhiske	lowerwhiske	Logged GDP p	Social suppor	Healthy life e	Freedom to r
2	Finland	Western Euro	1	7.808700085	0.031156305	7.869766235	7.747633934	10.63926697	0.954329729	71.9008255	0.949172199
3	Denmark	Western Euro	2	7.645599842	0.033492286	7.711244583	7.579955101	10.77400112	0.955990791	72.40250397	0.951444268
4	Switzerland	Western Euro	3	7.559899807	0.035014171	7.628527641	7.491271973	10.97993279	0.942846596	74.10244751	0.921336651
5	Iceland	Western Euro	4	7.504499912	0.059615862	7.621346951	7.387652874	10.77255917	0.974669576	73	0.948891878
6	Norway	Western Euro	5	7.487999916	0.034837384	7.55628109	7.419718742	11.08780384	0.952486575	73.20078278	0.955750287
7	Netherlands	Western Euro	6	7.448900223	0.02779175	7.503372192	7.394428253	10.81271172	0.93913883	72.30091858	0.908547819
8	Sweden	Western Euro	7	7.353499889	0.036234196	7.424519062	7.282480717	10.75879383	0.926311195	72.60076904	0.939144194
9	New Zealand	North Americ	8	7.299600124	0.039465468	7.376952648	7.222247601	10.50094318	0.949118972	73.20262909	0.936217487
10	Austria	Western Euro	9	7.294199944	0.033365164	7.359595776	7.228804111	10.7428236	0.928045869	73.00250244	0.899989486

Abbildung 2 – CSV-Datei: World Happiness Report 2015

	A	B	C	D
1	Entity	Code	Year	Political regi
2	Afghanistan	AFG	1789	0
3	Afghanistan	AFG	1790	0
4	Afghanistan	AFG	1791	0
5	Afghanistan	AFG	1792	0
6	Afghanistan	AFG	1793	0
7	Afghanistan	AFG	1794	0
8	Afghanistan	AFG	1795	0
9	Afghanistan	AFG	1796	0

Abbildung 3 – CSV-Datei: Political Regime Data-Set

	A	B	C	D	E	F	G	H	I	J	K
1	country	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959
2	Albania										
3	Argentina										
4	Armenia										
5	Antigua and Barbuda										
6	Australia	1	1.33	1.46	1.25	1.3	1.39	1.3	1.34	1.54	1.52
7	Austria						0.976	1.58	1.2	0.965	1.16
8	Azerbaijan										
9	Belgium					0.625	0.671	0.668	0.614	0.575	0.627

Abbildung 4 – CSV-Datei: Mordrate per 100.000 Einwohner Data-Set

Vergleicht man nun die obenstehenden Abbildungen Abbildung 2, Abbildung 3 und Abbildung 4 miteinander, fällt auf, dass Abbildung 2 (World Happiness Report 2015) pro Spalte verschiedene Informationen für das entspr. Land (Reihe) enthält und sich sämtliche Informationen auf das Jahr 2015 beziehen, Abbildung 3 (Political Regime Data-Set) pro Reihe Informationen über Land, Jahr und entspr. Wert enthalten und Abbildung 4 (Mordrate per 100.000 Einwohner Data-Set) pro Reihe ein Land beschreibt, die Werte für die einzelnen Jahre allerdings auf die Spalten verteilt wurden.

Jeder dieser drei Datensätze setzt voraus, dass sie – unabhängig davon, ob sie in-memory analysiert oder zunächst in andere Datensysteme überführt werden – jeweils speziell eingelesen und behandelt werden. Dies ist nötig, da die Informationen für die weitere Verarbeitung in einer einheitlichen Form vorliegen müssen.

Definition Datenbankschema

Um eine einheitliche Struktur für die Daten zu erzwingen, wurde entschieden, die Datensätze zunächst in einer Datenbank einzulesen. Hierfür musste zunächst das in Abbildung 5 dargestellte Datenbankschema definiert werden.

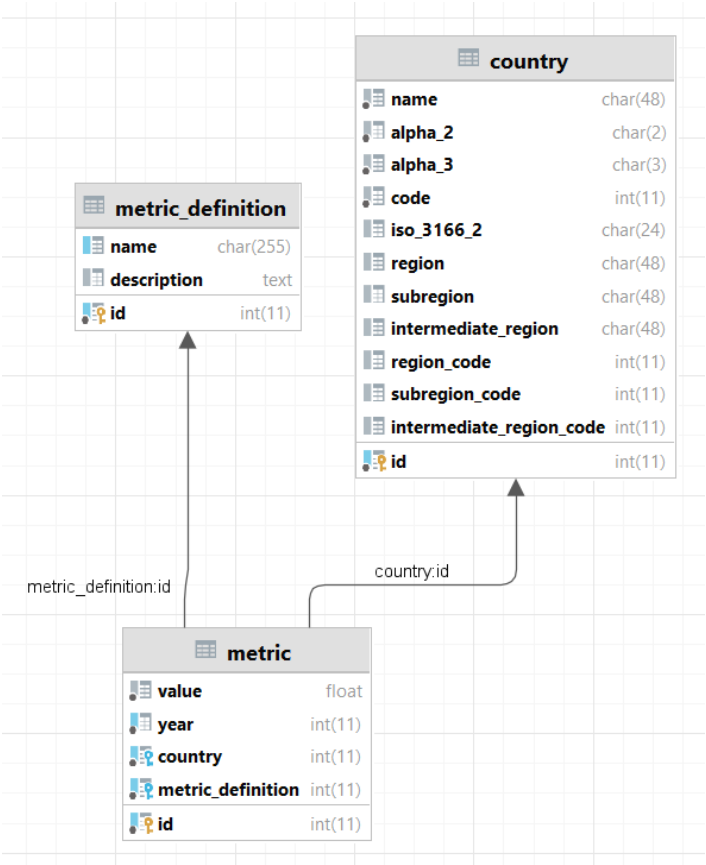


Abbildung 5 – DataGrip: Datenbankschema

Das Datenbankschema beschreibt eine Tabelle «*country*», eine Tabelle «*metric*» und eine Tabelle «*metric_definition*», welche im Folgenden detaillierter erklärt werden.

Tabelle «*country*»

Es wurde beschlossen, dass zunächst Basisinformationen zu allen Ländern in der Tabelle «*country*» bereitgestellt werden müssen, um einerseits relevante Informationen zu den einzelnen Nationen wie Name, Ländercode, Region, Kontinent, etc. und andererseits eine normalisierte Zuordnung zu den Metriken bereitstellen zu können.

Tabelle «*metric_definition*»

Weiter wurde einer Tabelle «*metric_definition*» definiert, welche schlicht die Namen und ggf. eine Beschreibung der jeweiligen Metriken beinhaltet. Bspw. könnte hier der Name «*Happyness Score*» und die Beschreibung «*Beschreibt den Zufriedenheitsindex des jeweiligen Landes auf einer Skala von 1 bis 10*» beinhalten.

Tabelle «*metric*»

Die Tabelle «*metric*» wurde definiert, um effektiv die Daten der jeweiligen Metrikdefinitionen und Länder zu beinhalten. Eine Metrik beinhaltet daher den Wert (bspw. einen Happyness Score von 7.6) für die verlinkte Metrikdefiniton (hier Happyness Score) für das verlinkte Land (bspw. die Schweiz) und eine Information für welche Jahr diese Information erhoben wurde.

Konvertierung

Zuvor wurde das Datenbankschema definiert, in welches die XLSX- und CSV-Daten übertragen werden sollen. Wie bereits in «*Prüfung des Rohdatenformats*» beschrieben, müssen die meisten dieser Dateien gesondert behandelt werden, da sie unterschiedlich aufgebaut sind.

Einige der Herausforderungen sind bspw.:

- Unterschiede in Anordnungen und Strukturen, wie in «*Prüfung des Rohdatenformats*» dargestellt
- Verschieden benannte Spalten und Zeilen
- Fehlende Daten (leere Felder)
- Nicht einheitliche Zahlenformate, wie «*1k*» statt «*1000*»

Zur Konvertierung bzw. Übernahme der Daten in die Datenbank entspr. dem o.g. Datenbankschema wurde mit Jupyter Notebooks (IPython, 2024) gearbeitet. Jupyter Notebooks bieten eine IDE für Python (Python Software Foundation, 2024), welche es ermöglichen den Code in kleine Abschnitte zu unterteilen und bei Bedarf mehrfach oder in verschiedenen Reihenfolgen auszuführen. Das mach diese Technologie zu einem geeigneten Werkzeug, um mit Daten zu experimentieren. Auf Basis dieser Jupyter Notebook kann später eine vollwertige und eigenständig lauffähige Applikation entstehen.

Zunächst wurde die Datei eingelesen:

```
whr = pd.read_csv("../data/worldhappinessreport/2015.csv", delimiter=",")
```

Damit wurde ein sog. Dataframe erstellt, welches nun die Daten aus der obenstehenden CSV-Datei enthält. Anschliessend muss eine Datenbankverbindung hergestellt werden, was mit dem folgenden Code geschieht.

```
maria_db_connection = None

try:
    maria_db_connection = mariadb.connect(
        user="root",
        password="password",
        host="127.0.0.1",
        port=30091,
        database="bina"
    )

    maria_db_connection.autocommit = False
except mariadb.Error as mdb_e:
    print(f"Fehler bei MaridDB Verbindungsaufbau: {mdb_e}")
```

Mit dem Überspringen einiger Einzelheiten und Details zum Code, kann mit dem nun folgenden Code der Inhalt der originalen Datei, welcher sich in diesem Dataframe befindet, in die Datenbank übertragen bzw. gespeichert werden.

```
cursor = maria_db_connection.cursor()

for metric in metrics:
    try:
        for index, row in whr[[country_column_name, metric]].iterrows():
            country = map_country(row[country_column_name])
            value = row[metric]

            select_statement = "select id from country where name=?"
            cursor.execute(select_statement, (country,))
            country_id = cursor.fetchone()

            if country_id is None:
                print("could not find country id: " + country)
                continue

            country_id = country_id[0]

            insert_statement = "insert into metric(name, value, year, country)
VALUES (?, ?, ?, ?)"

            cursor.execute(insert_statement, (map_metric_name(metric), value, year,
country_id,))
            maria_db_connection.commit()
    except KeyError as ke:
        print("could not find column for metric: " + metric)
        continue
    except DataError as de:
        print("could not insert value: " + str(value) + " for metric: " +
str(metric))
        continue

maria_db_connection.close()
```

Meta-Datenanalyse

Die Daten aus den gesammelten XLSX- und CSV-Dateien wurden erfolgreich bereinigt und in die Datenbank übertragen. Theoretisch könnte nun mit der eigentlichen Analyse der Daten begonnen werden, um die Forschungsfragen zu beantworten.

Doch zuvor müssen die Daten noch vorsortiert werden. Es werden Daten zu verschiedenen Ländern und verschiedenen Jahren untersucht und es liegt nahe, dass nicht zu jedem Land in jedem Jahr für jede Metrik ausreichend Daten zur Verfügung stehen, um damit statistisch signifikante Resultate zu erzielen.

Aus diesem Grund werden die gesammelten, bereinigten Daten nun anhand ihrer Metadaten untersucht und diejenigen Länder und Jahre ausgeschlossen, welche keine ausreichenden Informationen bieten.

Als Beispiel wird hier aufgeführt, wie das Team mit dem folgenden Query ein einfaches Set an Metadaten generiert, welche eine Grobe Übersicht über die Informationsdichte der einzelnen Länder zwischen 2015 und 2019 liefern. Der Zeitraum wurde auf 2015 bis 2019 eingeschränkt, da die Daten ab 2020 generell eher spärlich ausfallen, was ggf. der Pandemie geschuldet sein kann.

```
with metric_overview as (select metric.country, metric.year, count(distinct
metric.metric_definition) as count_metrics
                         from metric
                         where year between 2015 and 2019
                         group by country, year
                         order by count_metrics desc)
select country.name,
       avg(count_metrics) as avg_metrics_per_country,
       min(count_metrics) as min_metrics_per_country,
       max(count_metrics) as max_metrics_per_country
from metric_overview
         join country on metric_overview.country = country.id
group by country.name
order by avg_metrics_per_country;
```

Mit dem obenstehenden Query werden Informationen über die Informationen generiert. Wie bspw.:

- Wie viele verschiedene Metriken beschreiben das entspr. Land durchschnittlich zwischen 2015 und 2019?
- Wie viele Metriken beschreiben das entspr. Land min. zwischen 2015 und 2019
- Wie viele Metriken beschreiben das entspr. Land max. zwischen 2015 und 2019

	name	avg_metrics_per_country	min_metrics_per_country	max_metrics_per_country
1	Saint Martin (French part)	1.0000	1	1
2	Gibraltar	2.0000	2	2
3	Macao	2.0000	2	2
4	Liechtenstein	2.0000	2	2
5	New Caledonia	2.4000	2	3
6	Aruba	3.0000	3	3
7	Marshall Islands	3.0000	3	3
8	Tuvalu	3.0000	3	3
9	Turks and Caicos Islands	3.0000	3	3
10	Nauru	3.0000	3	3

Abbildung 6 - DataGrip: Metadatenauswertung

Diese Informationen führen dazu, dass einige Länder aus der Analyse aufgrund zu weniger Daten ausgeschlossen werden. Ein Beispiel hierfür ist das Land «***Liechtenstein***». Es hat nur 2 Metriken, welche es beschreiben und aufgrund seiner geringen Bevölkerungsdichte und seiner Nähe zu Deutschland, Schweiz und Österreich können hier Annahmen, die für die genannten Länder getroffen werden, auch auf dieses übertragen werden.

Des Weiteren fallen viele weitere kleinere Inselstaaten aus der Analyse wie auch Autokratien, welche keine Studien zulassen, welche wiederum zu Informationen führen könnten. Ein Beispiel hierfür ist «***Nordkorea***». Weiter fallen Länder aus der Analyse, welche keine ausreichende Infrastruktur für die Durchführung solcher Studien zulassen wie bspw. einige afrikanische Länder wie «***Eritrea***».

Datenanalyse

Nun kann die eigentliche Datenanalyse begonnen werden. Das Team hat auf seinem Weg bis hierher definiert, welche Ziele mit der Analyse verfolgt werden soll (Schritt 1 – Forschungsfragen wurden definiert), es hat die benötigen Daten – oder zumindest die Daten, von denen es anfangs ausging, dass sie benötigt werden – beschafft (Schritt 2 – Datenbeschaffung) und hat die Daten so aufbereitet (Schritt 3 – Datenanalyse), dass sie in einer einheitlichen Form vorliegen, aus einem System stammen und diese anhand der generierten Metadaten vorausgewählt.

Korrelationsanalyse

Die Frage nach den Zusammenhängen zwischen verschiedenen Metriken des WHR und weiterer additionaler Daten wirft wiederum die Frage auf, wie diese Daten generiert werden sollen. Das Team entscheidet sich dazu eine Korrelationsanalyse auf die Daten anzuwenden.

Konkret entscheidet sich hierbei das Analysten-Team für die Anwendung der Pearson-Korrelation (Wikipedia, 2024). Diese bietet den Vorteil, dass sie Skaleneffekte automatisch eliminiert und somit keine Normalisierung der Daten notwendig ist.

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\left(\sum_{i=1}^{n}(x_i - \bar{x})^2\right)\left(\sum_{i=1}^{n}(y_i - \bar{y})^2\right)}}$$

Abbildung 7 - Formel: Korrelation nach Pearson

Hierfür benötigt das Team zunächst einen entspr. Datensatz. Dieser wird mit dem folgenden SQL-Query beispielhaft für den Kontinent «*Europa*» aus der Datenbank abgefragt.

```
select country, metric_definition, metric.value
from metric
         join country on metric.country = country.id
where year = 2015
  and country in
      (list_of_countries)
  and metric_definition not in (1, 3)
  and country.region = 'Europe';
```

Der SQL-Query selektiert hier das Land, die ID der Metrikdefinition und den entspr. Wert für das Jahr 2015 für alle ausgewählten Länder und schliesst Metrikdefinitionen aus, die nicht ausschlaggebend sind (1 Happiness Rank – das ist nicht der Happiness Score – und die Metrik «*standard error*») für alle Länder der Region «*Europa*».

Im Folgenden wird der Anfang der ausgegebenen Tabelle angeschnitten. Es wird eine Referenz auf das entspr. Land ausgegeben, eine Referenz auf die entspr. Metrikdefinition und der zugehörige Wert.

	country	metric_definition	value
1	128	2	5.754
2	4	2	5.605
3	142	2	5.477
4	162	2	5.268
5	248	2	5.129
6	206	2	5.057
7	151	2	5.013
8	152	2	4.971
9	126	2	4.898
10	227	2	4.739

Abbildung 8 – DataGrip: Query-Resultat aus Abfrage zu Metriken

Allerdings werden die Daten in einer anderen Form benötigt. Die **Zeilen** müssen den **Ländern** entsprechen und die **Spalten** müssen jeweils den **jeweiligen Metrikdefinitionen** entsprechen. Die Inhalte werden die Werte der entspr. Metriken für das Land im angegebenen Jahr sein. Um dies zu erreichen, müssen die Daten aus dem SQL-Query in ein Dataframe überführt werden, welches dieses Format widerspiegelt. Dies wird mit dem folgenden Skript erreicht.

```
sql_data = pd.read_sql(sql_query, maria_db_connection)

unique_metric_definition_ids = sql_data["metric_definition"].unique()
count_unique_metric_definition_ids = len(unique_metric_definition_ids)

unique_country_ids = sql_data["country"].unique()
count_countries = len(unique_country_ids)

columns = ["country"] + unique_metric_definition_ids.tolist()
df = pd.DataFrame(index=range(count_countries), columns=columns)

for index, country_id in enumerate(unique_country_ids):
    df.at[index, "country"] = country_id

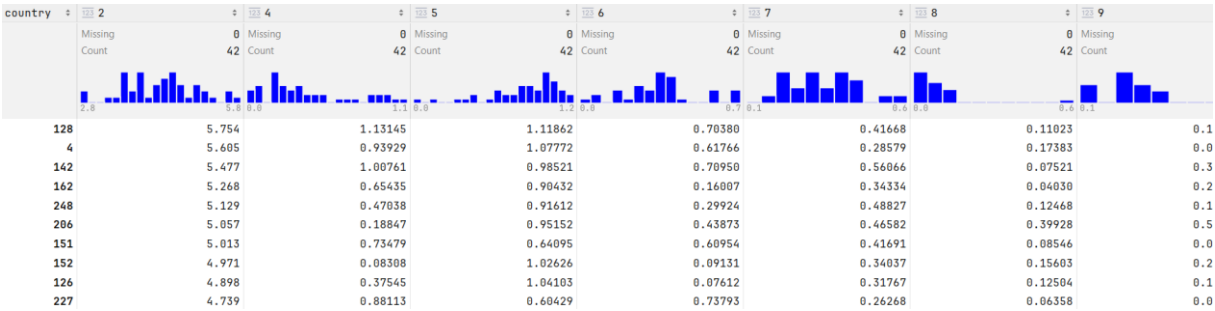
df.set_index("country", inplace=True)

for index, data in sql_data.iterrows():
    country_id = data["country"]
    metric_definition_id = data["metric_definition"]
    metric_value = data["value"]

    df.at[country_id, metric_definition_id] = metric_value

df.fillna(value=0, inplace=True)
```

Nachdem die Daten von diesem Skript verarbeitet wurden, stehen sie – wie oben beschrieben – in dem gewünschten Format zur Verfügung.

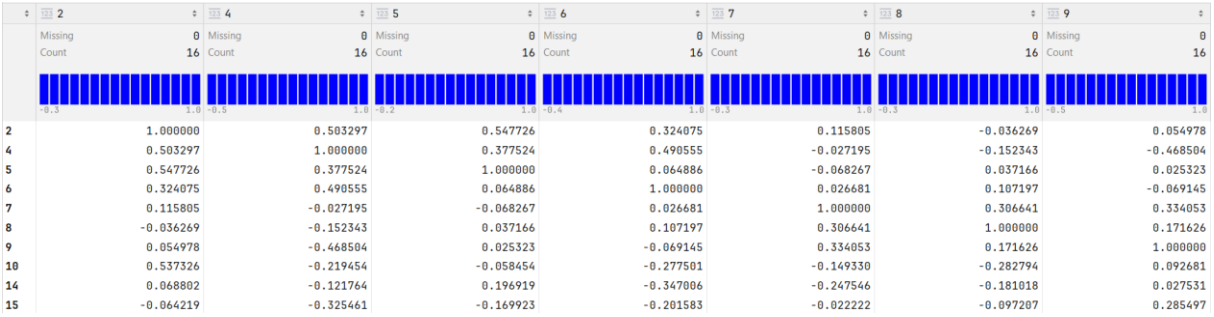


country	2	4	5	6	7	8	9
	Missing 0 Count 42	Missing 0 Count 42	Missing 0 Count 42	Missing 0 Count 42	Missing 0 Count 42	Missing 0 Count 42	Missing 0 Count
128	5.754	1.13145	1.11862	0.70380	0.41668	0.11023	0.1
4	5.605	0.93929	1.07772	0.61766	0.28579	0.17383	0.0
142	5.477	1.00761	0.98521	0.70950	0.56066	0.07521	0.3
162	5.268	0.65435	0.90432	0.16007	0.34334	0.04030	0.2
248	5.129	0.47038	0.91612	0.29924	0.48827	0.12468	0.1
206	5.057	0.18847	0.95152	0.43873	0.46582	0.39928	0.5
151	5.013	0.73479	0.64095	0.60954	0.41691	0.08546	0.0
152	4.971	0.08308	1.02626	0.09131	0.34037	0.15603	0.2
126	4.898	0.37545	1.04103	0.07612	0.31767	0.12504	0.1
227	4.739	0.88113	0.60429	0.73793	0.26268	0.06358	0.0

Abbildung 9 – Dataframe: Query-Resultat nach der Verarbeitung durch das Skript

«*country*» bildet den Index (die Referenz auf das Land in der Datenbank) und die Spalten bilden die Metrikdefinitionenreferenzen. Die Inhalte sind die entspr. Werte.

Zur Beantwortung der Forschungsfragen hat sich das Team dazu entschlossen eine Korrelationsanalyse durchzuführen. Die Korrelationsanalyse kann für die genutzten Dataframes automatisch mit der sog. Corr()-Methode automatisch durchgeführt werden. Die Ergebnisse werden von dieser Methode zunächst in einem weiteren Dataframe ausgegeben. Ein entspr. Beispiel ist in **Abbildung 6** zu sehen.



	2	4	5	6	7	8	9
	Missing 0 Count 16	Missing 0 Count 16	Missing 0 Count 16	Missing 0 Count 16	Missing 0 Count 16	Missing 0 Count 16	Missing 0 Count 16
2	1.000000	0.503297	0.547726	0.324075	0.115805	-0.036269	0.054978
4	0.503297	1.000000	0.377524	0.490555	-0.027195	-0.152343	-0.468504
5	0.547726	0.377524	1.000000	0.064886	-0.068267	0.037166	0.025323
6	0.324075	0.490555	0.064886	1.000000	0.026681	0.107197	-0.069145
7	0.115805	-0.027195	-0.068267	0.026681	1.000000	0.306641	0.334053
8	-0.036269	-0.152343	0.037166	0.107197	0.306641	1.000000	0.171626
9	0.054978	-0.468504	0.025323	-0.069145	0.334053	0.171626	1.000000
10	0.537326	-0.219454	-0.058454	-0.277501	-0.149330	-0.282794	0.092681
14	0.068802	-0.121764	0.196919	-0.347006	-0.247546	-0.181018	0.027531
15	-0.064219	-0.325461	-0.169923	-0.201583	-0.022222	-0.097207	0.285497

Abbildung 10 – Dataframe: Korrelationstabelle für Kontinent Europa für 2015

Diese Daten sind für Menschen schlecht zu interpretieren. Daher wird dieses von der `Corr()`-Methode generierte Dataframe dazu verwendet, eine Heatmap aufzubereiten.

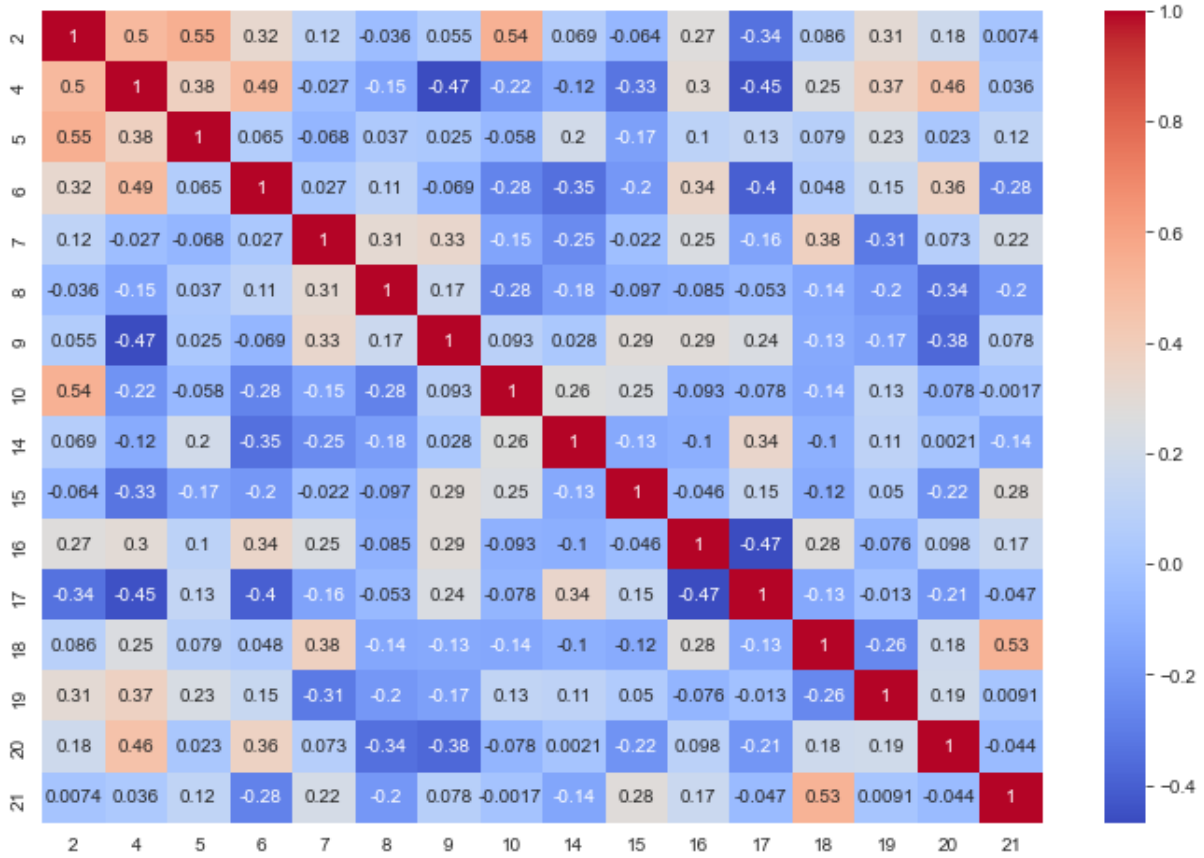


Abbildung 11 - Heatmap für Korrelationstabelle für Kontinent Europa für 2015

Diese Heatmap zeigt an, zwischen welchen Variablen starke positive Korrelationen (1, rot) und zwischen welchen starke negative Korrelationen (-1, blau) bestehen sowie alle möglichen reellen Werte zwischen -1 und 1.

Positive Korrelation

Eine positive Korrelation deutet an, dass je grösser Variable A ausfällt, desto grösser auch Variable B ausfällt. Dies ist insbesondere auf der Diagonalen zu sehen, welche die Variablen jeweils mit sich selbst korreliert, was zwangsläufig in einer maximal starken positiven Korrelation niederschlägt. Diese Art Korrelationen sind rot eingefärbt.

Negative Korrelation

Eine negative Korrelation deutet das genaue Gegenteil einer positiven Korrelation an. Je grösser Variabel A ausfällt, desto niedriger fällt Variable B aus. Diese Art Korrelationen sind blau eingefärbt.

Neutrale Korrelation

Eine neutrale Korrelation deutet an, dass keine Korrelation zwischen diesen beiden Werten besteht und keine Rückschlüsse von Variable A auf Variable B gezogen werden können. Diese Art Korrelation ist grau eingefärbt.

Zusammenfassung

Es wurde beschrieben, wie die beschafften Daten gesichtet, in eine Datenbank in ein einheitliches Schema überführt, bereinigt und ausgewertet wurden. Des Weiteren wurde der erstandene Prozess der Überführung der Daten aus einem SQL-Query, welcher alle benötigten Daten abfragt, in ein korrekt ausgelegtes Dataframe dargelegt. Die Analyse der Daten anhand einer einfachen Korrelationsanalyse sowie die Interpretation deren Ergebnisse wurde erläutert.

Der Prozess, um an die Übrigen Daten zu gelangen ist nun für jede Region und Kontinent derselbe. Die Datenanalyse ist somit abgeschlossen. Damit können die Resultate nun im folgenden Kapitel visuell aufbereitet werden.

Kapitel 4 – Präsentation der Resultate

Im Folgenden Kapitel wird auf Schritt 4 des «*five-step approach to data-driven decision-making*» eingegangen. Der vierte und vorletzte Schritt befasst sich mit der korrekten Präsentation der Daten. Es wird unterstrichen, wie eine gut vorbereitete und ordentliche Präsentation der Daten die Entscheidungsträger unterstützen aber auch beeinflussen kann. Ebenso werden verschiedene Präsentationsarten angegangen.

Diesen effektiv letzten Schritt mit der ebenso grossen Sorgfalt durchzuführen wie die Schritte der Definition der Ziele, der Datenbeschaffung und der Datenanalyse, ist daher enorm wichtig. Die Kommunikation der Ergebnisse ist ein elementarer Bestandteil des Analysewesens.

Visualisierung

Es existieren verschiedenste Arten der Visualisierung. Gemeint sind hierbei verschiedene Arten, Daten darzustellen – in erster Linie anhand verschiedener Charts. Die folgenden Infografiken (ein ironisches Beispiel für die Visualisierung von Daten über die Visualisierung an Daten) liefert eine gute erste Übersicht über die zur Verfügung stehenden Arten von Visualisierungen in Form von Charts.

Vergleiche

Für die visuelle Aufbereitung von Datenvergleichen – bspw. den Umsatzzahlen verschiedener Jahre – können Charts wie bspw. Bar-Charts, Column-Charts oder Dot-

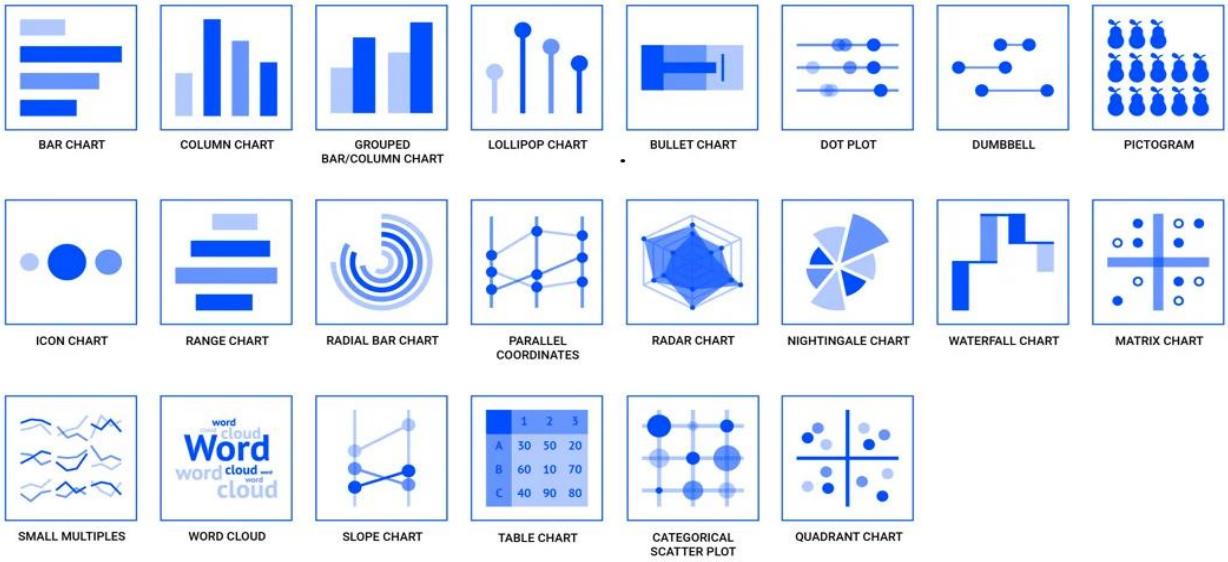


Abbildung 12 - Chart-Übersicht: Vergleiche (Datylon, 2024)

Plots verwendet werden. Nachfolgend eine grafische Darstellung möglicher Charts.

Korrelationen (Zusammenhänge)

Für die Darstellung von Korrelationen und anderer Zusammenhänge, bieten sich die eben vorgestellten Charts nicht an. Ein Beispiel für die Darstellung von Korrelationen wurde im vorherigen Kapitel mit dem Einsatz einer Heatmap zur Visualisierung der Korrelationsmatrix bereits eingebracht. Nachfolgend werden noch weitere Korrelations-geeignete Charts vorgestellt.

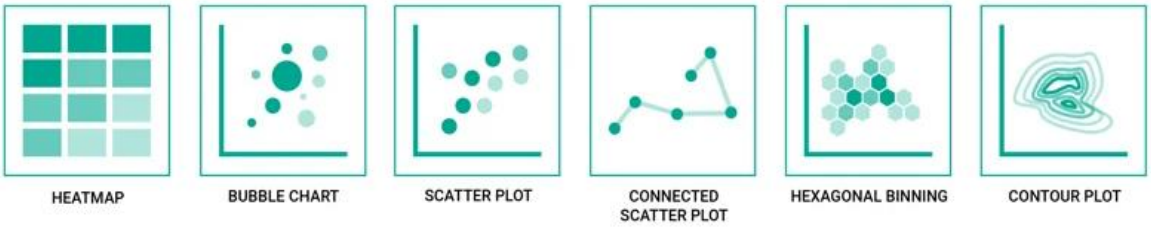


Abbildung 13 - Chart-Übersicht: Korrelationen (Datylon, 2024)

Teil eines Ganzen (Hierarchien)

Weiterhin existieren noch Fälle, in welchen Daten hierarchisch angeordnet werden müssen oder dargestellt werden muss, wie sich ein Datum oder ein Objekt innerhalt eines weiteren verortet. Für diesen Anwendungsfall wurden weiter Charts entworfen wie bspw. das sog. «*stacked bar / column chart*», das allseits bekannte Pie-Chart, oder das «*semi-circle doughnut chart*». Es folgen weitere Charts, welche sich eignen Hierarchien aller Art darzustellen.

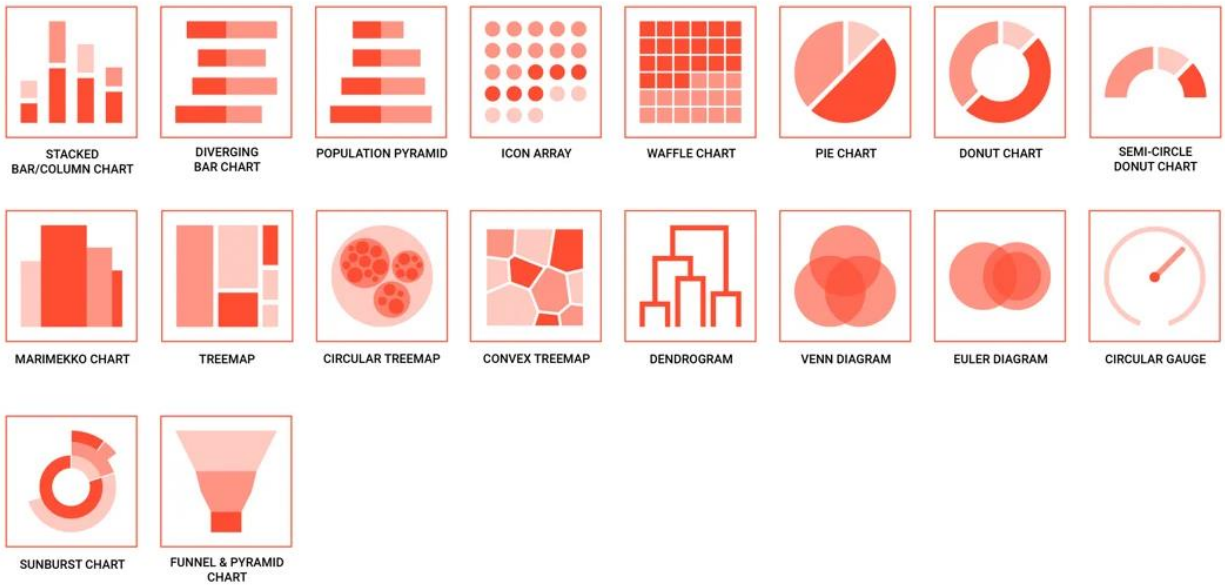


Abbildung 14 - Chart-Übersicht: Hierarchien (Datylon, 2024)

Zeitreihendaten

Anwendung finden durchaus auch Charts, welche Zeitreiheninformationen darstellen müssen. Ein klassisches Beispiel hierfür ist das sog. Line-Chart, welches sich bspw. dafür einsetzen lässt, darzustellen, wie sich der Umsatz über die letzten Monate oder Jahre entwickelt hat. Nachfolgend eine kleine Übersicht über mögliche Charts für den genannten Einsatzzweck.

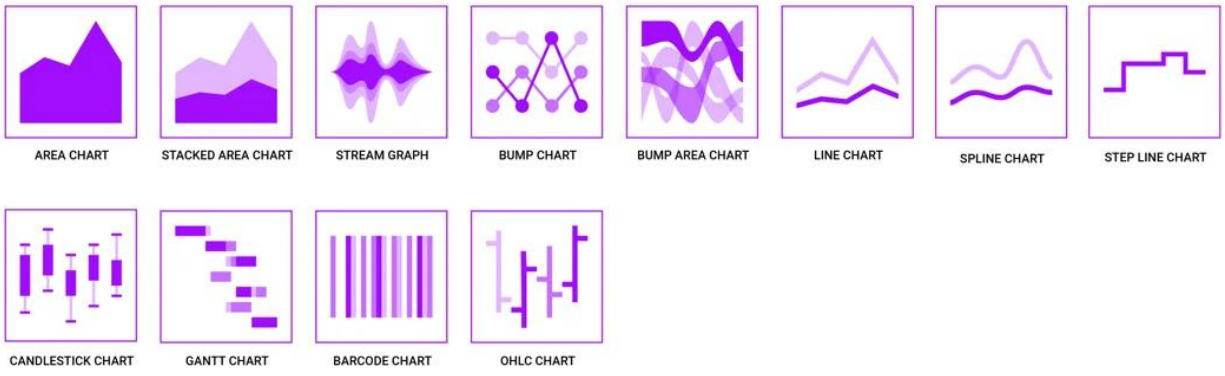


Abbildung 15 - Chart-Übersicht: Zeitreihendaten (Datylon, 2024)

Verteilung

Ebenso wichtig wie die bereits vorgestellten Arten, ist die Visualisierung von Verteilungen. Hierzu zählt bspw. die Verteilung von Einkommen über die verschiedenen Bevölkerungsgruppen oder Altersklassen. Beispiele für solche Charts wären das Histogramm, das Box-Chart oder der Violin-Plot. Diese werden im Folgenden ergänz.

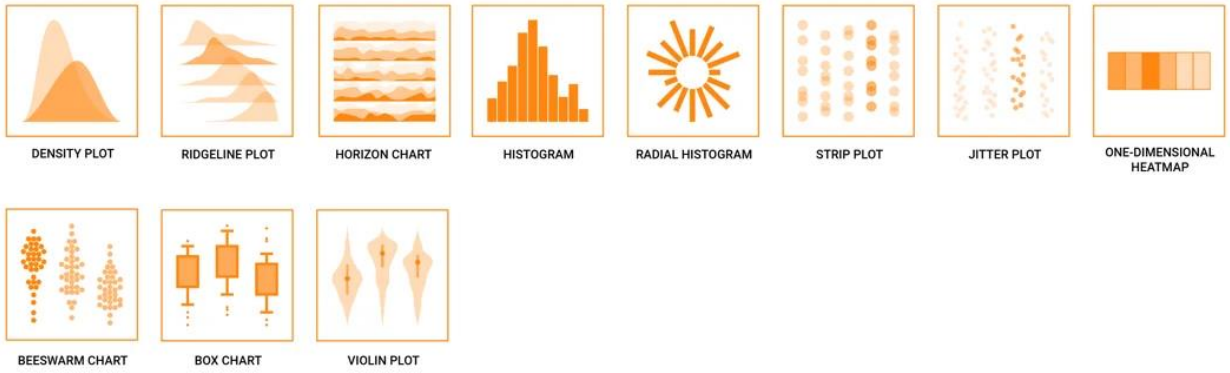


Abbildung 16 - Chart-Übersicht: Verteilungen (Datylon, 2024)

Geografie & Andere

Zu guter Letzt existiert noch eine spezielle Art der Visualisierung, welche vor Allem dann zum Einsatz kommt, wenn die Daten sich auf Länder beziehen. Die sog. geographische Visualisierung nutzt eine Landkarte, um Daten darzustellen. Des Weiteren werden im Folgenden noch einige nicht weiter zuordenbare Charts vorgestellt, die allerdings dennoch Verwendung finden und bekannt sein sollten.

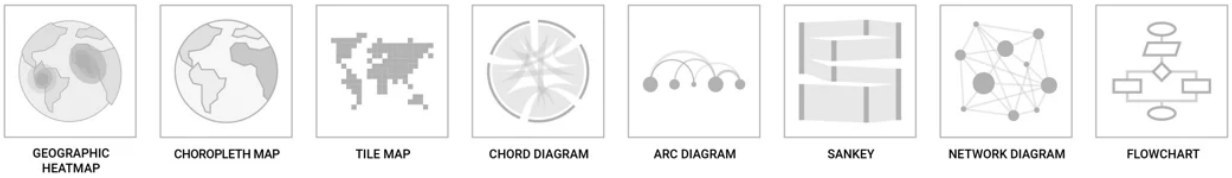


Abbildung 17 - Chart-Übersicht: Geografie und Andere (Datylon, 2024)

Resultate

Nachdem nun ein guter Überblick über die verschiedenen Visualisierungsarten erlangt wurde, die Datenbeschaffung erfolgreich war und die Datenanalyse durchgeführt wurde, kann nun damit begonnen werden die Resultate entspr. zu visualisieren.

In diesem Abschnitt wird nochmals Stück für Stück auf die Forschungsfragen und ihre Unterfragen eingegangen und anhand der visualisierten Ergebnisse erläutert. Die Visualisierung der Resultate der Datenanalyse wird auch auf den Folien der Präsentation, welche im Anhang dieser Arbeit wiederzufinden sind, zu finden sein.

Forschungsfrage 1 – «Welche Indikatoren des WHR haben einen signifikanten Einfluss auf die Zufriedenheit einer Bevölkerung»

Diese Forschungsfrage ist unterteilt in zwei Unterfragen. Die erste bezieht sich zunächst auf die top drei Einflüsse auf die Zufriedenheit der Menschen und die zweite auf die bottom drei Einflüsse. Es wird im Folgenden auf die top drei Einflüsse eingegangen.

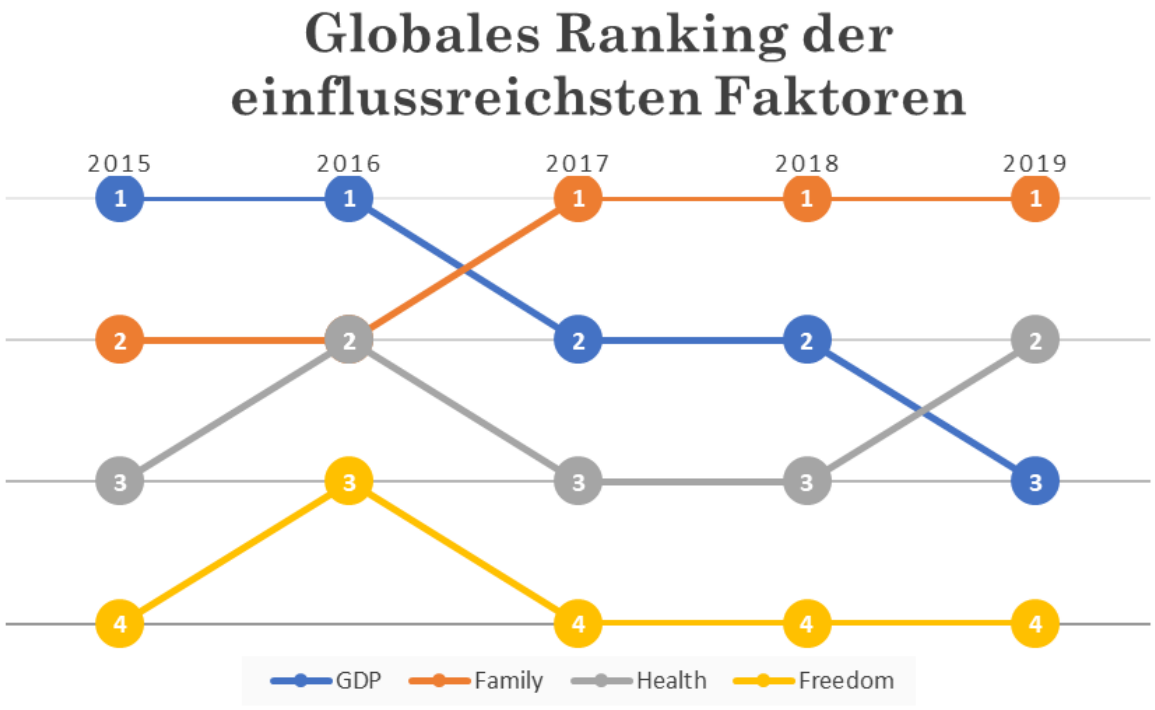


Abbildung 18 - Zeitreihendiagramm: Glob. Ranking top drei

Hier ist zu sehen, dass global bzw. generell gesehen in den letzten Jahren vor Allem das Thema «*Familie*» – also sozialer Rückhalt – an Bedeutung gewonnen hat. Auf er anderen Seite hat das Einkommen an Relevanz verloren. Die hier festgestellten top drei Einflussfaktoren sind damit für die zusehenden Zeiträume «*Familie*», «*Lebenserwartung*» und «*BIP pro Kopf*».

Die zweite Unterfrage bezog sich auf die entspr. gegenteilige Frage. Nämlich, welche Bereiche die für die Zufriedenheit der Bevölkerung unwichtigsten sind.

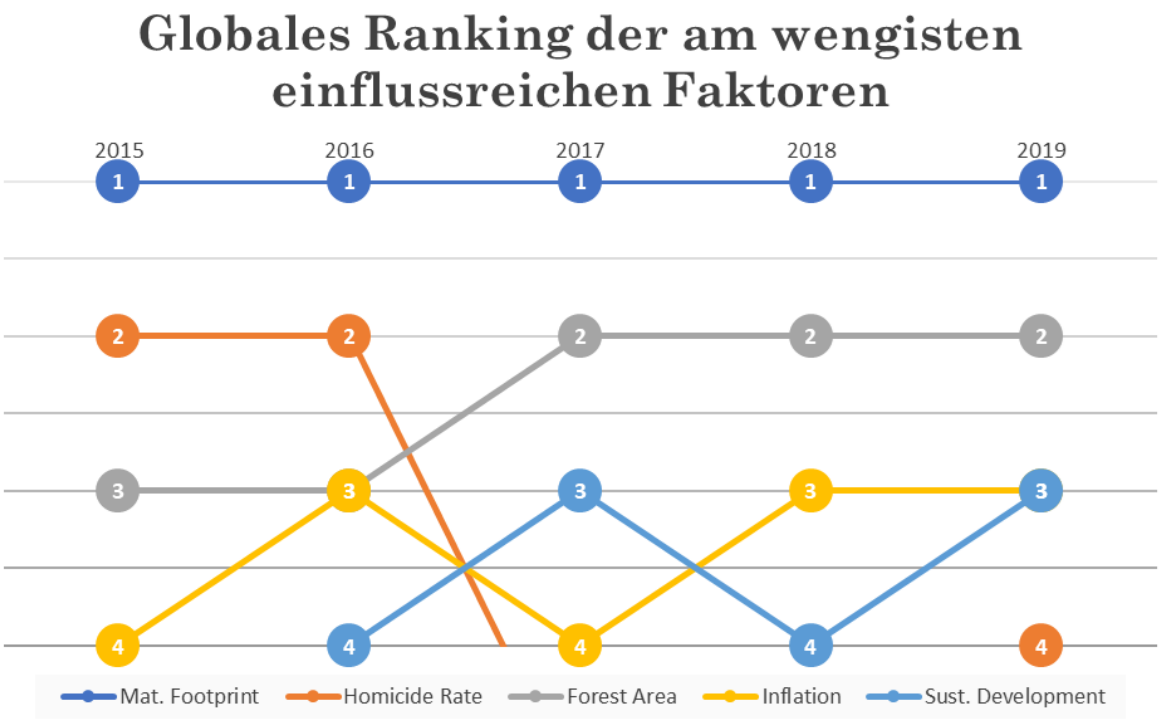


Abbildung 19 - Zeitreihendiagramm: Glob. Ranking bottom drei

Anhand dieses Charts kann abgeleitet werden, dass die am wenigsten relevanten Bereich für die Zufriedenheit der Menschen konstant beim «materiellen Fussabdruck» liegen, welcher keine besondere Auswirkung auf die Zufriedenheit der Menschen zu haben schein. Dies wird an der gegen Null gehenden Korrelation der Werte festgemacht. Des Weiteren ist zu sehen, dass die Mordrate an Bedeutung gewonnen zu haben scheint, denn sie verschwindet ab 2016 aus den top drei. Prominent sind damit der «materielle Fussabdruck», die «Waldfläche» sowie die beiden Werte «Inflation» und «sustainable development».

Forschungsfrage 2 – «Unterscheiden sich die relevanten Indikatoren verschiedener Regionen»

Die zweite Forschungsfrage beschäftigt sich mit den Unterschieden zwischen verschiedenen Regionen. Konkret ist hier die Frage nach den Unterschieden in den relevanten Indikatoren. Die zweite Forschungsfrage wird zudem konkretisiert mit der Frage nach den Unterschieden der relevanten Indikatoren zwischen verschiedenen Kontinenten. Hierfür hat das Analysten-Team die Daten der Kontinente Europa, Amerika (Nord- und Südamerika), Asien sowie Afrika ausgewertet. Die Resultate werden im Folgenden erläutert. Zunächst werden die Resultate zu Afrika betrachtet.

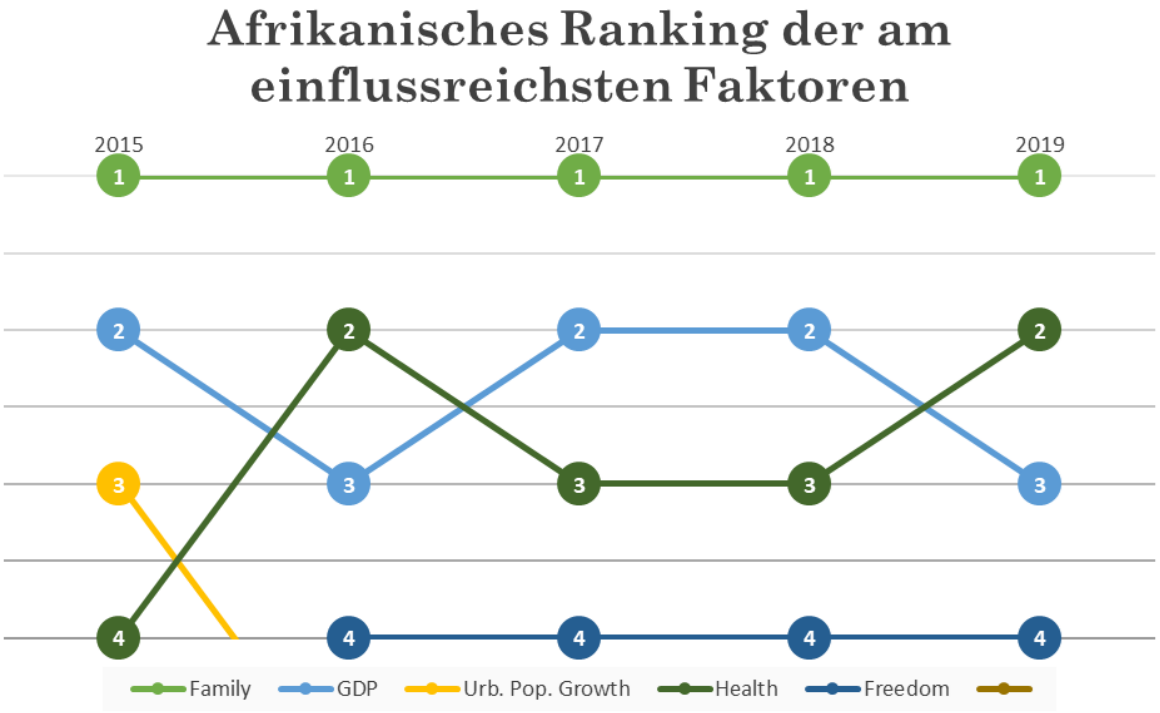


Abbildung 20 - Zeitreihendiagramm: Afr. Ranking top drei

Wie hier zu sehen ist, hat auf dem Afrikanischen Kontinent der familiäre Zusammenhalt eine zentrale Rolle inne. Dicht dahinter folgen das «*BIP pro Kopf*» sowie die Lebenserwartung der Menschen

Wenn wir uns nun im Gegensatz dazu das Beispiel aus Nord- und Südamerika anschauen, werden wir einige Unterschiede feststellen.

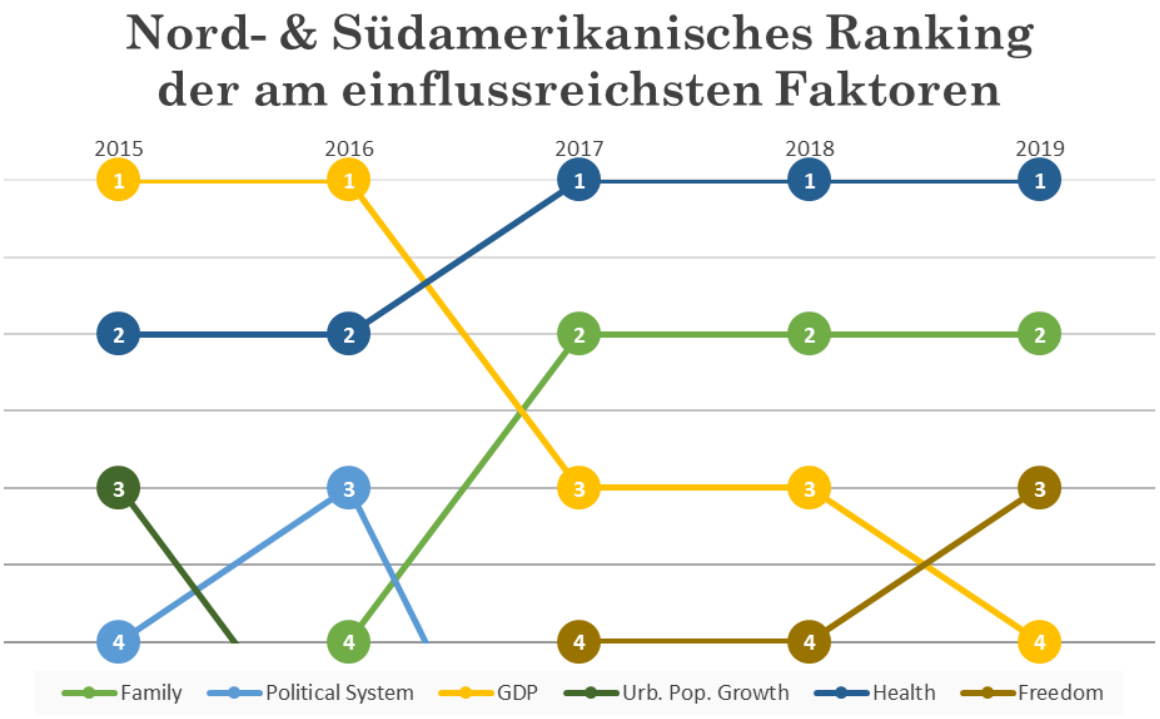


Abbildung 21 - Zeitreihendiagramm: Nord- & Südam. Ranking top drei

Hier hat zunächst das «*BIP pro Kopf*» eine wichtige Position, wird aber nach und nach abgelöst durch das Thema Gesundheit und Familie.

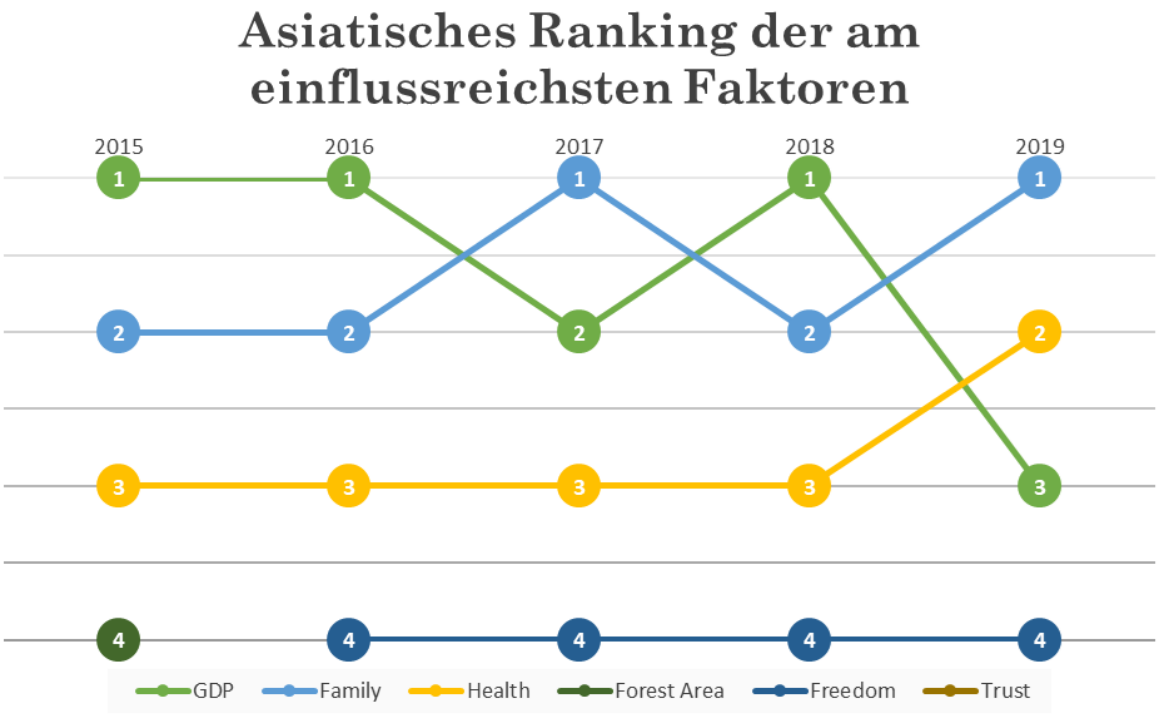


Abbildung 22 - Zeitreihendiagramm: Asia. Ranking top drei

Die Asiatischen Länder halten ebenfalls das «BIP pro Kopf» sehr hoch, dicht gefolgt von familiärer Unterstützung und dem Themenbereich Gesundheit.

Zu guter Letzt wird nun noch ein Blick auf den Graphen der Europäer geworfen.

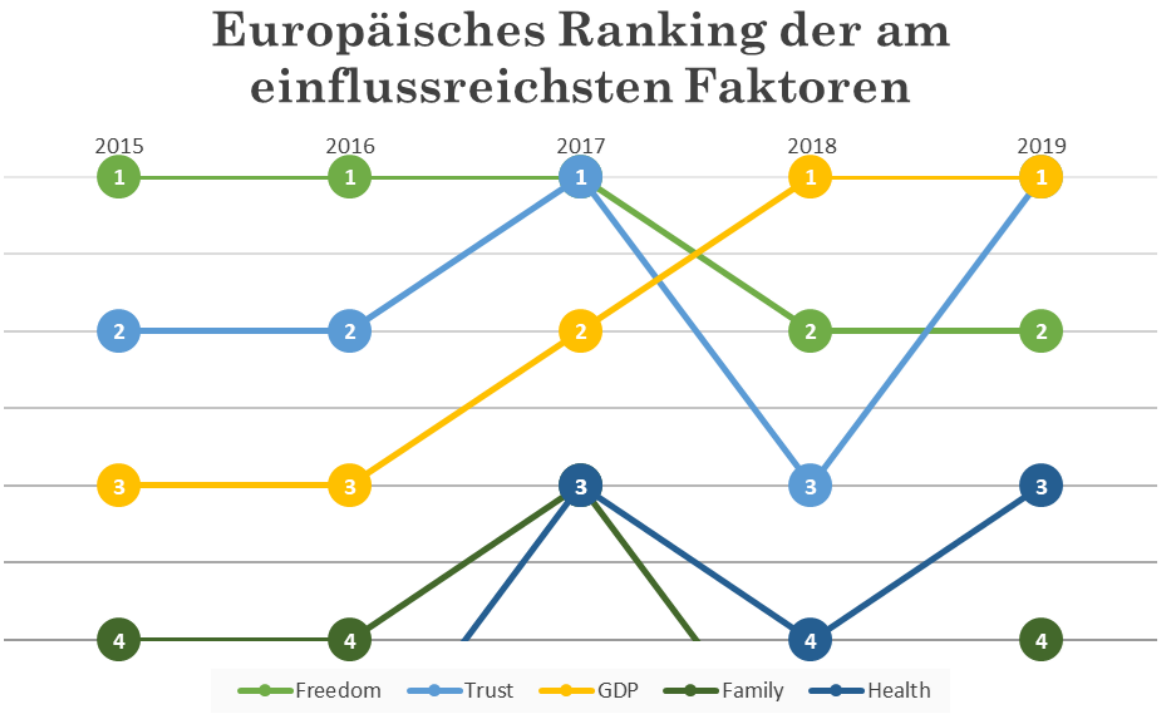


Abbildung 23 - Zeitreihendiagramm: Eur. Ranking top drei

Für die Europäer ist das Thema Freiheit an erster Stelle (würde man dieses auch eher bei den Amerikanern erwarten – aber Achtung: Die Auswertung erfolgte für «die Americas» und nicht für die USA allein). An zweiter Stelle steht das Vertrauen in die Regierung, welches für die Europäer einen hohen Stellenwert hat. Dicht gefolgt vom Thema «BIP pro Kopf».

Zusammenfassung

In diesem Kapitel wurden einige Visualisierungsarten vorgestellt und angewandt, um die Resultate der Datenanalyse zu visualisieren und dem Leser dieser Arbeit näher zu bringen. Es wurde ein Gesamtüberblick über die wichtigsten Faktoren der Zufriedenheit über alle Länder der Erde vermittelt sowie eine abgegrenzte Übersicht, welche die auf die jeweiligen Kontinente konzentriert.

Rückblick

Diese Arbeit sollte dem Leser einen Eindruck darüber vermittelt haben, wie der «*five-step approach to data-driven decision-making*» anzuwenden ist, und was die Vorteile der Anwendung dieser Vorgehensweise sind. Es wurde erläutert, in welche Schritte sich diese Vorgehensweise aufteilt und wie diese Schritte konkret zu implementieren sind. Anhand von Beispielen wurde verdeutlicht, wie diese Implementationen der Schritte aussehen könnten.

Mit den Resultaten kann die Geschäftsführung nun entscheiden, in welchen Bereichen sie weiter forschen möchten und wo es sich lohnen würde, weitere Mühen und Ressourcen zu investieren. Oder aber die Geschäftsführung kommt zu dem Ergebnis, dass die Resultate so nicht zufriedenstellen sind. In diesem Fall müssten die Ziele nochmal geklärt werden, mehr Daten beschafft und nochmal analysiert werden.

Ausblick

Sollte die Geschäftsführung mit den Resultaten soweit zufrieden sein und damit arbeiten können, so wären die nächsten Schritte, anhand dieser Daten bzw. Resultate weitere Unterbereiche zu definieren und für diese den «*five-step approach to data-driven decision-making*» zu wiederholen. Es könnte zum Beispiel sich auf einen Kontinent – auf einen Absatzmarkt – konzentriert und die entsprechenden Themenbereiche konkretisiert werden

Würde die Geschäftsführung sich bspw. auf Amerika konzentrieren und dort weiter forschen wollen, wäre die sinnvollste Variante, dass sich auf die Themenbereiche «Gesundheit» und «Familie» konzentriert wird und diese Märkte weiter untersucht werden.

Literaturverzeichnis

Datylon. (23. 06 2024). *80 types of charts & graphs for data visualization*. Von 80 types of charts & graphs for data visualization: https://www.datylon.com/blog/types-of-charts-graphs-examples-data-visualization abgerufen

GitHub. (23. 06 2024). *GitHub*. Von ISO-3166-Countries-with-Regional-Codes: https://github.com/lukes/ISO-3166-Countries-with-Regional-Codes/blob/master/all/all.csv abgerufen

IPython. (23. 06 2024). *Jupyter*. Von Jupyter: https://jupyter.org/ abgerufen

Marr, B. (undatiert). *From Data to Decisions.* Chartered Professional Accounts Canada.

Python Software Foundation. (23. 06 2024). *Python*. Von Python: https://www.python.org/ abgerufen

WHR, et. al. (23. 06 2024). *World Happiness Report*. Von World Happiness Report: https://worldhappiness.report/about/ abgerufen

Wikipedia. (23. 06 2024). *Korrelationskoeffizient nach Bravais-Pearson*. Von Korrelationskoeffizient nach Bravais-Pearson: https://de.wikipedia.org/wiki/Korrelationskoeffizient_nach_Bravais-Pearson abgerufen

World Bank, n. (kein Datum). *World Bank*. Von https://data.worldbank.org/indicator abgerufen

Abbildungsverzeichnis

Abbildung 1 – Skizze: Die fünf Schritte des data-driven decision-making 0
Abbildung 2 – CSV-Datei: World Happiness Report 2015.....8
Abbildung 3 – CSV-Datei: Political Regime Data-Set.....8
Abbildung 4 – CSV-Datei: Mordrate per 100.000 Einwohner Data-Set.....8
Abbildung 5 – DataGrip: Datenbankschema 9
Abbildung 6 - DataGrip: Metadatenauswertung 12
Abbildung 7 - Formel: Korrelation nach Pearson 13
Abbildung 8 – DataGrip: Query-Resultat aus Abfrage zu Metriken.....14
Abbildung 9 – Dataframe: Query-Resultat nach der Verarbeitung durch das Skript.....15
Abbildung 10 – Dataframe: Korrelationstabelle für Kontinent Europa für 2015.....15
Abbildung 11 - Heatmap für Korrelationstabelle für Kontinent Europa für 2015 16
Abbildung 12 - Chart-Übersicht: Vergleiche (Datylon, 2024).....19
Abbildung 13 - Chart-Übersicht: Korrelationen (Datylon, 2024) 19
Abbildung 14 - Chart-Übersicht: Hierarchien (Datylon, 2024) 20
Abbildung 15 - Chart-Übersicht: Zeitreihendaten (Datylon, 2024).....20
Abbildung 16 - Chart-Übersicht: Verteilungen (Datylon, 2024).....21
Abbildung 17 - Chart-Übersicht: Geografie und Andere (Datylon, 2024) 21
Abbildung 18 - Zeitreihendiagramm: Glob. Ranking top drei 22
Abbildung 19 - Zeitreihendiagramm: Glob. Ranking bottom drei 23
Abbildung 20 - Zeitreihendiagramm: Afr. Ranking top drei.....24
Abbildung 21 - Zeitreihendiagramm: Nord- & Südam. Ranking top drei 25
Abbildung 22 - Zeitreihendiagramm: Asia. Ranking top drei.....25
Abbildung 23 - Zeitreihendiagramm: Eur. Ranking top drei.....26

Eigenständigkeitserklärung

Hiermit erklären wir, dass die vorliegende Arbeit selbstständig verfasst wurde und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt wurden.

Alle sinngemäss und wörtlich übernommenen Textstellen aus fremden Quellen wurden kenntlich gemacht.

Ort, Datum: Uzwil & Sursee, 23.06.2024



Annamária Sréter



Pjeter Bushi